

**LAPORAN PRAKTIKUM
KECERDASAN BUATAN**
*REGRESI LINIER SEDERHANA & REGRESI LINIER
BERGANDA*



Fani Namesia R. Sianturi
42324045
D3 Teknologi Informasi

INSTITUT TEKNOLOGI DEL
FAKULTAS VOKASI
TAHUN AJARAN
2026/2027

Simple Linear Regression

- Membaca data

```
import pandas as pd
df = pd.read_csv('Data_Gaji.csv')
print(df.head())
```

[5] ✓ 0.0s Python

	YearsExperience	Salary
0	1.1	39343.0
1	1.3	46205.0
2	1.5	37731.0
3	2.0	43525.0
4	2.2	39891.0

Terlihat ada dua kolom. Karyawan dengan pengalaman 1,1 tahun bergaji 39.343, sedangkan yang berpengalaman 2,2 tahun bergaji 39.891. Data ini sudahurut dari pengalaman terkecil.

- **Menentukan X dan y**

Sekarang kita tentukan mana kolom yang jadi bahan untuk menebak (X) dan mana yang jadi hasil yang ditebak (y) dari tabel data, untuk Simple Linear Regression


```
X = df.iloc[:, :-1].values
y = df.iloc[:, 1].values
```

[6] ✓ 0.0s Python

Sedikit penjelasan kodenya: `iloc[:, :-1]` artinya "ambil semua baris, dan semua kolom kecuali kolom terakhir". Sementara `iloc[:, 1]` artinya "ambil semua baris dari kolom nomor 1" (hitungan dimulai dari 0, jadi kolom ke-2). Akhiran `.values` mengubah hasilnya menjadi array NumPy yang siap dipakai Scikit-Learn

- **Melihat sebaran data**

Sebelum membuat model, ada baiknya kita lihat dulu bentuk datanya lewat *scatter plot*. Setiap titik mewakili satu karyawan: posisi kiri-kanan menunjukkan lama pengalaman, posisi atas-bawah menunjukkan gaji.



Dari grafik terlihat titik-titik naik dari kiri bawah ke kanan atas dan membentuk pola yang hampir lurus. Karena polanya lurus, regresi linear cocok dipakai di sini. Kalau polanya melengkung tajam atau acak, garis lurus tidak akan mewakilinya dengan baik.

- **Membagi data latih dan data uji**

Kita membagi data menjadi dua bagian: **80% data latih** untuk belajar dan **20% data uji** untuk ujian. Analoginya seperti belajar untuk ujian: latihan soal dipakai untuk belajar, sedangkan soal ujian harus soal yang belum pernah dilihat. Kalau model diuji dengan data yang sama dengan data belajarnya, nilainya bisa terlihat bagus padahal model hanya menghafal.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0)
```

[14] ✓ 0.0s Python

- **test_size = 0.2** berarti 20% data dijadikan data uji.
- **random_state = 0** mengunci cara pengacakan supaya pembagian datanya sama setiap kali kode dijalankan. Tanpa ini, hasil R-Square bisa berubah-ubah tiap dijalankan.

□ Melatih model

Inilah inti prosesnya. Kita membuat model kosong dengan `LinearRegression()`, lalu memanggil `fit()` untuk melatihnya dengan data latih. Saat `fit()` berjalan, model mencari garis lurus dengan jarak total terkecil ke semua titik data latih. Cara mencarinya disebut *least squares* (kuadrat terkecil).

```
# Fitting Simple Linear Regression to the Training set
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

[15] ✓ 0.5s Python

LinearRegression ⓘ ?

- Parameters
- Fitted attributes

Setelah `fit()` selesai, model sudah "pintar" dan menyimpan dua angka penting: intercept dan slope, yang kita baca di langkah berikutnya.

• Membaca intercept dan slope

Garis regresi berbentuk $\hat{y} = a + bx$. Angka a dan b dihitung otomatis oleh model.

- **Intercept (a)** adalah titik awal garis, yaitu perkiraan gaji kalau pengalaman kerja 0 tahun.
- **Slope (b)** adalah kemiringan garis, yaitu seberapa besar gaji naik setiap pengalaman bertambah 1 tahun.

```
a = regressor.intercept_
b = regressor.coef_[0]
print("Estimated model intercept, a:", a)
print("Estimated model slope, b:", b)
print(f"ŷ = {a:.2f} + {b:.2f}x")
```

[16] ✓ 0.0s Python

Estimated model intercept, a: 26780.09915062818
Estimated model slope, b: 9312.575126729189
ŷ = 26780.10 + 9312.58x

• Contoh memakai persamaan untuk menebak

Setelah punya persamaan, kita bisa menebak gaji untuk pengalaman berapa pun dengan cara memasukkan angkanya ke x.

```
# memprediksi hasil pada data uji (Test set) menggunakan model regresi
y_pred = regressor.predict(X_test)
y_pred

[17] ✓ 0.0s Python

... array([ 40748.96184072, 122699.62295594,  64961.65717022,  63099.14214487
          115249.56285456, 107799.50275317])
```


Setelah model dilatih, kita coba pakai untuk menebak gaji pada data uji (X_{test}) yang belum pernah dilihat model. Hasilnya (y_{pred}) adalah kumpulan angka gaji hasil tebakan model untuk tiap baris data uji. Angka-angka ini yang nanti dibandingkan dengan gaji asli (y_{test}) untuk mengukur seberapa akurat modelnya.

```
# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi
# Semakin mendekati 1, semakin baik model
from sklearn.metrics import r2_score
score=r2_score(y_test,y_pred)
score


[18] ✓ 0.0s Python

... 0.988169515729126
```


Untuk mengukur seberapa bagus tebakan model, dihitung nilai R-Square dengan membandingkan y_{test} (gaji asli) dan y_{pred} (gaji tebakan). Hasilnya 0,988, artinya model bisa menjelaskan sekitar 98,8% variasi gaji hanya dari lama pengalaman kerja. Angka ini sangat dekat dengan 1, jadi model sudah sangat baik.



Grafik ini menunjukkan hasil model pada data latih. Titik merah adalah data asli karyawan, sedangkan garis biru adalah garis regresi yang dibentuk model. Garis birunya mengikuti pola titik merah dengan cukup rapat, artinya model berhasil menangkap hubungan antara pengalaman dan gaji dari data latihnya.



Sekarang giliran data uji yang digambar. Titik merah adalah gaji asli pada data uji, garis biru tetap garis regresi dari data latih tadi. Karena titik-titik merah juga jatuh dekat dengan garis biru, model bekerja baik bukan hanya untuk data yang sudah dihafal, tapi juga untuk data baru yang belum pernah dilihat.



Bagian ini mulai membahas Multiple Linear Regression memakai dataset baru bernama kumpulan_data_regresi_linear_ganda.csv. Datanya berisi tiga kolom: age (usia), experience (lama pengalaman), dan income (pendapatan). Berbeda dengan sebelumnya, kali ini ada dua variabel bebas (age dan experience) yang dipakai untuk menebak income.

```
[25] X2 = df2.iloc[:, :-1]
      y2 = df2.iloc[:, 2]
      Python 0.0s
```

Sama seperti sebelumnya, kita pisahkan kolom-kolom prediktor (X2) yaitu age dan experience, dari kolom target (y2) yaitu income. Bedanya, karena sekarang X2 berisi dua kolom sekaligus, model ini disebut regresi berganda (multiple regression) karena punya lebih dari satu variabel X.

```
[27] # Bagi dataset menjadi train dan test 80:20
      X_train2, X_test2, y_train2, y_test2 = train_test_split(
      |     X2, y2, test_size=0.2, random_state=0)
      Python 0.0s
```

Data kembali dibagi menjadi 80% data latih dan 20% data uji dengan `random_state=0`, mengikuti prinsip yang sama seperti pada Simple Linear Regression sebelumnya, supaya hasil pembagian datanya konsisten setiap kali kode dijalankan ulang.

```
[28] regressor = LinearRegression()
      regressor.fit(X_train2, y_train2)
      Python 0.0s
```

LinearRegression ⓘ ?

- Parameters
- Fitted attributes

Model regresi kembali dibuat dan dilatih, kali ini dengan `X_train2` dan `y_train2`. Prosesnya sama seperti sebelumnya, hanya saja sekarang model belajar mencari hubungan antara dua variabel (age dan experience) terhadap income.

```
[29] # Predicting the Test set results
      y_pred2 = regressor.predict(X_test2)
      print(y_pred2)
      Python 0.0s
```

```
[46487.25542968 34623.71312375 49379.11875301 38349.57565764]
```

Model yang sudah dilatih dipakai untuk menebak income pada data uji (X_test2). Hasilnya adalah empat angka pendapatan hasil tebakan model, satu untuk tiap baris data uji.

```
Generate Code Markdown

a_ = regressor.intercept_
b1 = regressor.coef_[0]
b2 = regressor.coef_[1]
print("Estimated model intercept, a:", a_)
print("Estimated model slope, b1:", b1)
print("Estimated model slope, b2:", b2)
print(f"ŷ = {a_:.2f} {b1:.2f}x1 + {b2:.2f}x2")

[30] ✓ 0.0s Python

... Estimated model intercept, a: 30945.793141906892
Estimated model slope, b1: -97.99352917934205
Estimated model slope, b2: 2205.9086190738694
ŷ = 26780.10 -97.99x1 + 2205.91x2
```

Di sini dibaca nilai intercept (a) dan dua slope (b1 untuk age, b2 untuk experience) hasil pelatihan model. Persamaan akhirnya menjadi $\hat{y} = 26780,10 - 97,99 \cdot x_1 + 2205,91 \cdot x_2$, artinya makin tua usia (x_1) hubungannya negatif dengan income pada model ini, sedangkan makin lama pengalaman kerja (x_2) hubungannya positif dan pengaruhnya cukup besar terhadap kenaikan income.

```
Generate Code Markdown

# Menghitung nilai R-Square, yang mengukur seberapa baik model regresi
# Semakin mendekati 1, semakin baik model
score2=r2_score(y_test2,y_pred2)
score2

[31] ✓ 0.0s Python

... 0.8872690560355565
```

Terakhir dihitung nilai R-Square untuk model regresi berganda ini, hasilnya 0,887. Artinya sekitar 88,7% variasi income bisa dijelaskan oleh kombinasi usia dan pengalaman kerja. Nilainya memang sedikit lebih rendah dibanding model sederhana tadi, tapi masih tergolong baik.

Tugas Praktikum W03S02

1. Simple Linear Regression: prediksi score (y) berdasarkan waktu belajar (X) dari dataset

<https://www.kaggle.com/datasets/snmahsa/student-scoresuitable-forlinear-regression>

```
import pandas as pd
df = pd.read_csv('rounded_hours_student_scores.csv')
print(df.head())
print(df.shape)
print(df.isnull().sum())
```

[33] ✓ 0.0s Python

	Hours	Scores
0	1.1	41
1	1.2	40
2	1.4	38
3	1.5	39
4	1.6	36


(60, 2)
Hours 0
Scores 0
dtype: int64

Cell ini membaca dataset `rounded_hours_student_scores.csv` lalu menampilkan 5 baris pertamanya, ukuran datanya (`df.shape`), dan jumlah data kosong di tiap kolom (`df.isnull().sum()`). Dari hasilnya terlihat dataset punya 60 baris dan 2 kolom yaitu Hours (jam belajar) dan Scores (nilai), serta tidak ada data yang kosong sehingga datanya siap dipakai langsung.

```
X = df.iloc[:, :-1].values
y = df.iloc[:, 1].values
```

[34] ✓ 0.0s Python

Cell ini menentukan variabel X dan y. X diambil dari semua kolom kecuali kolom terakhir, yaitu kolom Hours, sedangkan y diambil dari kolom Scores. Artinya kita ingin menebak nilai (Scores) berdasarkan lama waktu belajar (Hours).



Cell ini menggambar scatter plot untuk melihat sebaran data sebelum membuat model. Sumbu x menunjukkan jam belajar dan sumbu y menunjukkan nilai/score. Titik-titiknya terlihat naik dari kiri bawah ke kanan atas, menandakan makin lama belajar cenderung makin tinggi nilainya, meski sebarannya tidak serapi contoh gaji sebelumnya.

```
from sklearn import train_test_split
X_train, y_train, X_test, y_test = train_test_split(X, y, test_size=0.2, random_state=0)
```

[37] ✓ 0.0s Python

Cell ini membagi data menjadi data latih dan data uji dengan porsi 80:20 menggunakan `train_test_split`, sama seperti pola yang dipakai pada materi sebelumnya, dengan `random_state=0` supaya hasil pembagiannya tetap sama tiap kali dijalankan.

```
[38] from sklearn.linear_model import LinearRegression
      regressor = LinearRegression()
      regressor.fit(X_train, y_train)
      Python
```

LinearRegression ⓘ ?

- Parameters
- Fitted attributes

Cell ini membuat model regresi linear kosong lalu melatihnya (fit) dengan data latih X_{train} dan y_{train} , sehingga model mulai mencari garis lurus terbaik yang menghubungkan jam belajar dengan nilai.

```
[39] a = regressor.intercept_
      b = regressor.coef_[0]
      print("Estimated model intercept, a:", a)
      print("Estimated model slope, b:", b)
      print(f"ŷ = {a:.2f} + {b:.2f}x")
      Python
```

Estimated model intercept, a: 37.89028997006413
Estimated model slope, b: 1.6690585851433417
 $\hat{y} = 37.89 + 1.67x$

Cell ini menampilkan hasil pelatihan model berupa intercept ($a = 37,89$) dan slope ($b = 1,67$). Artinya kalau jam belajarnya 0, nilai perkiraannya sekitar 37,89, dan setiap tambahan 1 jam belajar diperkirakan menambah nilai sekitar 1,67 poin. Persamaan akhirnya adalah $\hat{y} = 37,89 + 1,67x$.

```
[40] y_pred = regressor.predict(X_test)
      y_pred
      Python
```

array([45.73486532, 47.73773562, 53.24562895, 46.06867704, 42.22984229,
40.22697199, 47.57082976, 53.07872309, 48.90607663, 44.73343017,
40.56078371, 42.06293643])


Cell ini memakai model untuk menebak nilai pada data uji (X_{test}). Hasilnya adalah kumpulan angka nilai (y_{pred}) yang nanti dibandingkan dengan nilai asli (y_{test}) untuk melihat seberapa dekat tebakan model dengan kenyataan.

```
from sklearn.metrics import r2_score
score = r2_score(y_test, y_pred)
score
```


[41] ✓ 0.0s Python

... 0.6886702273580021

Cell ini menghitung R-Square dari hasil tebakan model, hasilnya 0,689. Artinya model hanya mampu menjelaskan sekitar 68,9% variasi nilai siswa dari jam belajarnya. Nilai ini lebih rendah dibanding contoh gaji sebelumnya, kemungkinan karena nilai siswa tidak hanya dipengaruhi oleh jam belajar saja, tapi juga faktor lain yang tidak ada di dataset ini.



Cell ini menggambar hasil model pada data latih. Titik merah adalah data asli, garis biru adalah garis regresi yang dibentuk model. Garis birunya cukup mewakili arah naik dari data, meski masih banyak titik yang menyebar cukup jauh dari garis.



Cell ini menggambar hasil model pada data uji dengan cara yang sama. Titik-titik merah (nilai asli pada data uji) tersebar di sekitar garis biru (garis regresi), menunjukkan model cukup mampu memprediksi nilai siswa baru meskipun tidak sempurna, sejalan dengan nilai R-Square yang didapat sebelumnya.

2. Multiple Linear Regression: prediksi sales (y) berdasarkan data marketing (x) di youtube, facebook, newspaper, dari

dataset

<https://www.kaggle.com/fayejavad/marketinglinear-multiple-regression>

```
import pandas as pd
df = pd.read_csv('Marketing_Data.csv')
print(df.head())
print(df.shape)
print(df.isnull().sum())
print(df.corr())
```

[44] ✓ 0.0s Python

	youtube	facebook	newspaper	sales
0	84.72	19.20	48.96	12.60
1	351.48	33.96	51.84	25.68
2	135.48	20.88	46.32	14.28
3	116.64	1.80	36.00	11.52
4	318.72	24.00	0.36	20.88

(171, 4)

youtube 0
facebook 0
newspaper 0
sales 0
dtype: int64

	youtube	facebook	newspaper	sales
youtube	1.000000	0.086538	0.110759	0.782030
facebook	0.086538	1.000000	0.293425	0.602918
newspaper	0.110759	0.293425	1.000000	0.254987
sales	0.782030	0.602918	0.254987	1.000000

Cell ini membaca dataset Marketing_Data.csv lalu menampilkan 5 data teratas, ukuran data (171 baris, 4 kolom: youtube, facebook, newspaper, sales), jumlah data kosong (tidak ada yang kosong), dan tabel korelasi antar kolom. Dari tabel korelasi terlihat youtube punya korelasi paling kuat dengan sales (0,78), disusul facebook (0,60), sedangkan newspaper korelasinya paling lemah (0,25).

```
X = df.iloc[:, :-1]
y = df.iloc[:, -1]
```

[45] ✓ 0.0s Python

Cell ini menentukan X sebagai semua kolom kecuali kolom terakhir (youtube, facebook, newspaper) dan y sebagai kolom terakhir (sales). Kali ini ada tiga variabel bebas sekaligus yang dipakai untuk menebak sales.

```
from sklearn.model_selection import train_test_split
X_train, y_train, X_test, y_test = train_test_split(X, y, test_size=0.2, random_state=0)
```

[46] ✓ 0.0s Python

Cell ini membagi data menjadi data latih dan data uji dengan porsi 80:20 dan `random_state=0`, seperti biasa supaya hasil pembagian datanya konsisten.

```
from sklearn.linear_model import LinearRegression
regressor = LinearRegression()
regressor.fit(X_train, y_train)
```

[47] ✓ 0.0s Python

LinearRegression ⓘ ?

- Parameters
- Fitted attributes

Cell ini membuat model regresi dan melatihnya dengan `X_train` dan `y_train`, sehingga model belajar hubungan antara belanja iklan di youtube, facebook, dan newspaper terhadap penjualan (sales).

```
y_pred = regressor.predict(X_test)
print(y_pred)
```

[48] ✓ 0.0s Python

```
[17.47637032 16.37438329 23.03375348 24.76366742 18.44000541  9.88587684
 27.58148165 28.87880859 23.06393669 19.0636305  13.21803757 14.34999561
  9.23890874 13.14124811 10.24291776 16.2522827  20.0147228 25.73237296
 12.05155149 13.89264368 19.7192218  10.95264453 22.23454235 27.70965086
 20.47231834 11.94972356 19.4677982  15.98774074 23.2733346  20.3406546
 25.5594432  18.45251872  6.66383729 20.57898229 18.94707082]
```

Cell ini menebak nilai sales pada data uji menggunakan model yang sudah dilatih. Hasilnya berupa kumpulan angka prediksi penjualan untuk tiap baris data uji.

```
a_ = regressor.intercept_
b1 = regressor.coef_[0]
b2 = (variable) regressor.coef_[1]
b3 = regressor.coef_[2]

print("Estimated model intercept, a:", a_)
print("Estimated model slope, b1 (youtube):", b1)
print("Estimated model slope, b2 (facebook):", b2)
print("Estimated model slope, b3 (newspaper):", b3)
print(f"ŷ = {a_:.2f} + {b1:.4f}x1 + {b2:.4f}x2 + {b3:.4f}x3")
```

[49] ✓ 0.0s Python

... Estimated model intercept, a: 3.8558434315881716
Estimated model slope, b1 (youtube): 0.04381266146268516
Estimated model slope, b2 (facebook): 0.18387483267122112
Estimated model slope, b3 (newspaper): 0.00480963406943527
ŷ = 3.86 + 0.0438x1 + 0.1839x2 + 0.0048x3

Cell ini menampilkan intercept dan tiga slope hasil pelatihan model, satu slope untuk tiap variabel (youtube, facebook, newspaper). Persamaannya menjadi $\hat{y} = 3,86 + 0,0438 \cdot x_1 + 0,1839 \cdot x_2 + 0,0048 \cdot x_3$. Dari angka slope-nya terlihat facebook (b2) punya pengaruh terbesar terhadap kenaikan sales dibanding youtube dan newspaper, meski youtube justru paling berkorelasi tinggi di tabel korelasi sebelumnya.

```
from sklearn.metrics import r2_score
score2 = r2_score(y_test, y_pred)
score2
```

[50] ✓ 0.0s Python

... 0.9227472153504572

Cell ini menghitung R-Square model, hasilnya 0,923. Artinya sekitar 92,3% variasi penjualan bisa dijelaskan oleh kombinasi belanja iklan di ketiga media tersebut. Ini termasuk nilai yang tinggi, jadi model regresi berganda ini cukup baik dipakai untuk kasus ini.

```
import numpy as np
from sklearn.metrics import mean_absolute_error, mean_squared_error
print("MAE :", mean_absolute_error(y_test, y_pred))
print("RMSE:", np.sqrt(mean_squared_error(y_test, y_pred)))
```

[51] ✓ 0.0s Python

... MAE : 1.4463277567807389
RMSE: 1.8680947966215438

Cell ini menghitung dua ukuran error tambahan selain R-Square, yaitu MAE (rata-rata selisih absolut antara nilai asli dan prediksi) sebesar 1,45, dan RMSE (akar dari rata-rata kuadrat selisihnya) sebesar 1,87. Karena skala sales di dataset ini kecil, angka error yang kecil ini menunjukkan prediksi model cukup dekat dengan nilai aslinya.

```
import matplotlib.pyplot as plt


hasil = pd.DataFrame({'Aktual': y_test.values, 'Prediksi': y_pred})
print(hasil.head(10))

plt.scatter(y_test, y_pred, color='blue')
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()],
         color='red', linestyle='--')
plt.xlabel('Sales Aktual')
plt.ylabel('Sales Prediksi')
plt.title('Aktual vs Prediksi (Test set)')
plt.show()
```

[52] ✓ 0.1s Python

...	Aktual	Prediksi
0	16.32	17.476370
1	13.80	16.374383
2	23.28	23.033753
3	26.04	24.763667
4	18.72	18.440005
5	11.64	9.885877
6	30.48	27.581482
7	31.44	28.878809
8	23.52	23.063937
9	19.08	19.063630

Cell ini membuat tabel perbandingan antara sales aktual dan sales hasil prediksi untuk melihat langsung selisihnya per baris, sekaligus menyiapkan scatter plot yang membandingkan keduanya dengan garis putus-putus merah sebagai acuan, yaitu garis di mana nilai prediksi sama persis dengan nilai aktual.



Cell ini menampilkan grafik hasil perbandingan sales aktual dan prediksi. Semakin dekat titik birunya ke garis putus-putus merah, semakin akurat prediksi modelnya. Terlihat sebagian besar titik berkumpul rapat di sekitar garis tersebut, menandakan model regresi berganda ini sudah cukup baik dalam menebak penjualan berdasarkan data marketing

